Relatório — Classificador Bayesiano Gaussiano

1. Introdução

O presente relatório apresenta os resultados obtidos com a aplicação do Classificador Bayesiano Gaussiano ao conjunto de dados Spambase, como parte da Questão 2 do projeto de Aprendizagem de Máquina.

Para esta etapa, foi utilizada a versão original do conjunto de dados, mantendo a variável resposta original com duas classes: spam e não-spam.

O objetivo desta etapa foi avaliar o desempenho do classificador por meio de diferentes métricas de classificação e calcular intervalos de confiança de 95% para as estimativas obtidas.

2. Conjunto de dados

O conjunto Spambase utilizado possui 4601 observações e 57 variáveis explicativas.

A variável resposta original apresenta duas classes:

- classe 0: não-spam;
- classe 1: spam.

A distribuição das classes é composta por:

- 2788 exemplos de não-spam;
- 1813 exemplos de spam.

Assim, o problema considerado nesta etapa é uma classificação binária.

3. Classificador Bayesiano Gaussiano

O primeiro classificador avaliado na Questão 2 foi o Classificador Bayesiano Gaussiano.

O método utiliza o Teorema de Bayes para determinar a probabilidade de um exemplo pertencer a cada uma das classes. A decisão de classificação é realizada atribuindo o exemplo à classe que apresentar a maior probabilidade posterior.

A regra de decisão pode ser representada por:

$$\hat{y} = arg\ max_i\ P(\omega_i \mid x)$$

A probabilidade posterior é obtida a partir da combinação entre a probabilidade a priori da classe e a probabilidade de observar as características do exemplo considerando aquela classe.

Para cada classe, foi considerada uma distribuição normal multivariada, uma vez que o conjunto de dados possui múltiplas características.

Os parâmetros da distribuição, incluindo o vetor de médias e a matriz de covariância, foram estimados utilizando os dados disponíveis no conjunto de treinamento.

As probabilidades a priori foram estimadas por máxima verossimilhança, considerando a frequência de cada classe no conjunto de treinamento.

4. Procedimento de avaliação

A avaliação foi realizada utilizando a estratégia de 30 × 10-folds, com amostragem estratificada.

Nesse procedimento, foram realizadas 30 repetições de uma validação cruzada com 10 folds. Em cada fold, aproximadamente 90% dos dados foram utilizados para treinamento e 10% para teste.

Dessa forma, o procedimento resultou em:

30 × 10 = 300 avaliações externas

Como o Classificador Bayesiano Gaussiano não possui hiperparâmetros que precisassem ser selecionados por validação cruzada, não foi necessária a realização de uma etapa adicional de validação interna para escolha de parâmetros.

Em cada avaliação, o modelo foi treinado utilizando o conjunto de treinamento e posteriormente aplicado ao conjunto de teste.

Foram calculadas quatro métricas:

- taxa de erro;
- precisão;
- cobertura;
- F-measure.

5. Métricas utilizadas

5.1 Taxa de erro

A taxa de erro representa a proporção de exemplos classificados incorretamente e foi calculada por:

$$Taxa\ de\ erro = 1 - Acurácia$$

5.2 Precisão

A precisão representa a proporção de exemplos classificados como positivos que realmente pertencem à classe positiva:

$$Precisão = VP / (VP + FP)$$

5.3 Cobertura

A cobertura, também conhecida como recall, representa a proporção dos exemplos positivos reais que foram corretamente identificados:

$$Cobertura = VP / (VP + FN)$$

5.4 F-measure

A F-measure combina precisão e cobertura em uma única medida:

$$F_1 = 2 \times (Precisão \times Cobertura) / (Precisão + Cobertura)$$

6. Resultados obtidos

O arquivo CSV utilizado para este relatório contém quatro registros, um para cada métrica avaliada no Classificador Bayesiano Gaussiano.

Os valores registrados são:

Métrica	Estimativa pontual	IC 95% inferior	IC 95% superior
Taxa de erro	0,2184	0,2028	0,2339
Precisão	0,6781	0,6665	0,6896
Cobertura	0,9560	0,9535	0,9585
F-measure	0,7873	0,7783	0,7963

Em porcentagem:

Métrica	Estimativa	Intervalo de confiança de 95%
Taxa de erro	21,84%	20,28% – 23,39%
Precisão	67,81%	66,65% – 68,96%
Cobertura	95,60%	95,35% – 95,85%
F-measure	78,73%	77,83% – 79,63%

7. Análise dos resultados

A taxa de erro estimada foi de 21,84%, com intervalo de confiança de 95% entre 20,28% e 23,39%. Isso significa que, nas avaliações realizadas, a estimativa da proporção de classificações incorretas ficou em torno de 22%.

A precisão foi de 67,81%, com intervalo de confiança entre 66,65% e 68,96%. Esse resultado indica que, entre as observações classificadas como pertencentes à classe positiva, aproximadamente 67,81% foram corretamente classificadas como positivas.

A cobertura apresentou valor de 95,60%, com intervalo de confiança entre 95,35% e 95,85%. Portanto, o classificador identificou uma proporção elevada dos exemplos que realmente pertenciam à classe positiva.

A diferença entre precisão e cobertura é um aspecto importante do resultado. Enquanto a cobertura apresentou valor de 95,60%, a precisão foi de 67,81%. Isso indica que o comportamento do classificador não foi equilibrado entre essas duas medidas: ele conseguiu identificar grande parte dos exemplos positivos, mas uma parcela das previsões positivas foi incorreta.

A F-measure foi de 78,73%, com intervalo de confiança de 77,83% a 79,63%. Essa métrica fornece uma medida conjunta entre precisão e cobertura e resume o equilíbrio entre essas duas características do classificador.

8. Intervalos de confiança

Os intervalos de confiança de 95% registrados no CSV foram:

- Taxa de erro: [0,2028; 0,2339];
- Precisão: [0,6665; 0,6896];
- Cobertura: [0,9535; 0,9585];
- F-measure: [0,7783; 0,7963].

Os intervalos permitem apresentar não apenas uma estimativa pontual, mas também uma faixa associada à estimativa de cada métrica.

Entre as quatro métricas, a cobertura apresentou uma faixa relativamente estreita em torno de sua estimativa, variando de 95,35% a 95,85%.

9. Síntese dos resultados

De forma resumida, o desempenho obtido pelo Classificador Bayesiano Gaussiano foi:

Taxa de erro = 21,84%

Precisão = 67,81%

Cobertura = 95,60%

F-measure = 78,73%

Esses valores constituem os resultados registrados no arquivo resultado_bayesiano_gaussiano.csv.

10. Conclusão

A aplicação do Classificador Bayesiano Gaussiano ao conjunto Spambase apresentou uma taxa de erro de 21,84%, precisão de 67,81%, cobertura de 95,60% e F-measure de 78,73%.

O resultado evidencia uma diferença entre precisão e cobertura, com cobertura elevada e precisão inferior. Dessa forma, o classificador conseguiu identificar grande parte dos exemplos positivos, mas também apresentou classificações positivas incorretas.

Os intervalos de confiança de 95% foram calculados para todas as métricas e estão registrados no arquivo CSV utilizado na análise.

Esses resultados serão utilizados como referência para as próximas etapas da Questão 2, nas quais os demais classificadores serão implementados e avaliados utilizando o mesmo conjunto de métricas e procedimento de validação. Posteriormente, os resultados dos classificadores poderão ser submetidos às análises estatísticas previstas no projeto.