RELATÓRIO — CLASSIFICADOR BAYESIANO GAUSSIANO

Questão 2 — Projeto de Aprendizagem de Máquina | Base Spambase

1. Introdução

Este relatório apresenta a etapa realizada com o classificador Bayesiano Gaussiano na Questão 2. Até o momento, o foco foi a versão original da variável resposta da base Spambase, que distingue e-mails não spam e spam. Este é um relatório parcial: ele documenta o que foi implementado e avaliado até agora, sem afirmar que toda a Questão 2 foi concluída.

2. Dados utilizados

A base utilizada contém 4.601 e-mails e 57 atributos numéricos de entrada. A variável resposta possui duas classes: classe 0, com 2.788 exemplos (não spam), e classe 1, com 1.813 exemplos (spam). Na verificação realizada, não foram encontrados valores ausentes.

3. Como funciona o classificador

O classificador Bayesiano Gaussiano estima, para cada classe, sua probabilidade a priori, a média dos atributos e a matriz de covariância. Assume-se que os atributos de cada classe seguem uma distribuição normal multivariada. Ao receber um e-mail, o modelo calcula uma pontuação relacionada à probabilidade posterior de cada classe e escolhe a classe com maior valor.

4. Implementações comparadas

Foram comparadas duas implementações. A versão antiga estima a probabilidade a priori pela proporção de exemplos da classe, calcula a média e a covariância a partir do conjunto de treinamento e utiliza a pseudoinversa da covariância durante a previsão. A covariância é calculada com divisor n (bias=True), conforme a estimativa de máxima verossimilhança.

A versão nova também estima a priori e média, mas acrescenta uma pequena regularização à matriz de covariância e usa fatoração de Cholesky nos cálculos. A regularização pode melhorar a estabilidade numérica, embora altere a matriz de covariância estimada. Por isso, a versão antiga é mantida como referência mais direta ao enunciado, e a nova é apresentada como comparação.

5. Procedimento de avaliação

Foi utilizada validação cruzada estratificada 30 × 10-folds. Em cada repetição, os dados são divididos em dez partes mantendo aproximadamente a proporção entre as classes. O modelo é treinado em nove partes e avaliado na parte restante; o processo percorre as dez partes e é repetido 30 vezes. Assim, foram obtidas 300 avaliações por implementação. As duas versões utilizaram as mesmas divisões de treino e teste.

As métricas calculadas foram: taxa de erro, precisão, cobertura (recall) e F1. A taxa de erro indica a proporção de previsões incorretas; a precisão indica a proporção de previsões de spam que realmente eram spam; o recall indica a proporção dos e-mails spam identificados; e F1 combina precisão e recall.

6. Resultados da implementação antiga

Métrica	Média	Interpretação
Taxa de erro	0,2184 (21,84%)	Cerca de 22 erros a cada 100 e-mails.
Precisão	0,6781 (67,81%)	Cerca de 68% dos e-mails classificados como spam eram spam.
Recall / cobertura	0,9560 (95,60%)	Identificou cerca de 96% dos e-mails spam.
F1 / F-measure	0,7873 (78,73%)	Resumo do equilíbrio entre precisão e recall.

7. Comparação entre as duas implementações

A tabela apresenta a média e o desvio-padrão calculados sobre os 300 folds.

Métrica	Antiga (média ± DP)	Nova (média ± DP)	Melhor média
Erro	0,2184 ± 0,1373	0,1554 ± 0,0161	Nova: menor erro
Precisão	0,6781 ± 0,1018	0,7331 ± 0,0218	Nova
Recall	0,9560 ± 0,0221	0,9542 ± 0,0162	Antiga, por pequena diferença
F1	0,7873 ± 0,0795	0,8289 ± 0,0158	Nova

A versão nova apresentou menor taxa média de erro (15,54%, contra 21,84%), maior precisão (73,31%, contra 67,81%) e maior F1 (82,89%, contra 78,73%). O recall foi semelhante, com pequena vantagem da versão antiga (95,60%, contra 95,42%). Nesta experiência, a versão nova teve resultados médios melhores em três das quatro métricas.

8. Curva de aprendizagem

Também foi gerada uma curva de aprendizagem para o classificador Gaussiano usando a variável resposta original. Os arquivos de curva foram salvos separadamente no diretório de saída do projeto. A curva permite observar como o desempenho em F1 varia conforme aumenta a quantidade de dados usada no treinamento. Os valores detalhados devem ser consultados no arquivo CSV da curva produzido no Colab.

9. Situação atual e próximas etapas

Esta etapa cobre somente o classificador Bayesiano Gaussiano e a variável resposta original. Para concluir a Questão 2 ainda será necessário avaliar o classificador Bayesiano baseado em k-vizinhos, a janela de Parzen, a regressão logística e o voto majoritário; repetir os experimentos com a variável resposta baseada nos clusters de objetos da Questão 1; e realizar as comparações estatísticas e demais análises pedidas no enunciado.

Os intervalos de confiança e os testes de comparação entre classificadores serão organizados na etapa de consolidação do relatório, quando os resultados dos modelos estiverem reunidos.

10. Conclusão parcial

O classificador Bayesiano Gaussiano foi implementado e avaliado na base Spambase original por validação cruzada estratificada 30 × 10-folds. A implementação antiga segue de forma mais direta a

estimativa de máxima verossimilhança descrita no enunciado. A implementação regularizada obteve melhores médias de erro, precisão e F1, enquanto o recall permaneceu praticamente igual. O trabalho continua com os demais classificadores e as análises exigidas na Questão 2.