RELATÓRIO — CLASSIFICADOR BAYESIANO POR JANELA DE PARZEN

Questão 2 — Projeto de Aprendizagem de Máquina | Base Spambase

1. Introdução

Este relatório descreve a etapa do projeto dedicada ao classificador Bayesiano baseado na janela de Parzen. O experimento foi realizado com a variável resposta original da base Spambase, que distingue e-mails não spam e spam. O objetivo é registrar a implementação, a forma de avaliação e os resultados obtidos até agora. Este documento é parcial e não representa a conclusão de toda a Questão 2.

2. Relação com a Questão 2

A Questão 2 solicita a implementação e comparação de cinco classificadores. Um deles é o classificador Bayesiano por janela de Parzen, com kernel multivariado produto formado pelo kernel Gaussiano univariado. O enunciado pede que o parâmetro h seja escolhido por validação cruzada e que o desempenho seja avaliado por taxa de erro, precisão, cobertura (recall) e F-measure. Também estão previstas curvas de aprendizagem, comparações estatísticas entre modelos e experimentos com a variável resposta baseada nos clusters da Questão 1. Este relatório cobre somente o Parzen com os rótulos originais.

3. Descrição dos dados

Foi utilizada a base Spambase com 4.601 e-mails e 57 atributos numéricos de entrada. A variável resposta contém duas classes: classe 0 para e-mails não spam e classe 1 para e-mails spam. Na etapa de preparação documentada, a matriz X tinha dimensão (4601, 57), y_original continha 4.601 rótulos e não foram encontrados valores ausentes.

4. Como funciona a janela de Parzen

A janela de Parzen estima, para cada classe, o quanto um novo e-mail é compatível com os exemplos observados daquela classe. A função kernel dá maior influência aos exemplos próximos e menor influência aos mais distantes. Nesta implementação foi utilizado o kernel Gaussiano univariado em uma estrutura de kernel multivariado produto, conforme solicitado no enunciado.

O parâmetro h controla a largura da janela. Um h menor produz uma estimativa mais localizada e sensível aos exemplos próximos; um h maior suaviza a estimativa e considera uma região mais ampla. O classificador compara as estimativas para as classes e prevê aquela com maior pontuação posterior.

5. Implementação

No Google Colab foram utilizadas as funções treinar_parzen e prever_parzen_rapido. Antes da classificação, os atributos foram padronizados com StandardScaler. O scaler foi ajustado somente com os dados de treinamento de cada divisão e depois aplicado aos dados de validação ou teste correspondentes. Isso evita que informações dos dados de teste sejam usadas durante o ajuste do pré-processamento.

Os valores candidatos testados para h foram 0,1; 0,2; 0,5; 1,0; 2,0 e 5,0. A seleção do parâmetro foi feita usando a métrica F1 para a classe positiva, que representa spam.

6. Procedimento de avaliação e escolha de h

Foi utilizada validação cruzada estratificada repetida 30 × 10-folds. Em cada repetição, os dados foram divididos em dez partes preservando aproximadamente a proporção das classes. Em cada rodada, nove partes foram usadas para treinamento e uma para teste; o processo percorreu as dez partes e foi repetido 30 vezes, totalizando 300 avaliações externas.

Dentro de cada divisão externa, foi aplicada validação cruzada estratificada interna de cinco partes para escolher h. O valor que apresentou o melhor F1 médio na validação interna foi utilizado para treinar o modelo da divisão externa. Nos resultados registrados, h = 0,5 foi selecionado em todas as 300 divisões externas.

Para cada divisão externa foram calculadas taxa de erro, precisão, recall/cobertura e F1. As médias apresentadas a seguir resumem as 300 avaliações externas.

7. Resultados

Métrica	Média	Interpretação
Taxa de erro	0,0790 (7,90%)	Aproximadamente 8 classificações incorretas a cada 100.
Precisão	0,9126 (91,26%)	Cerca de 91% das mensagens marcadas como spam eram spam.
Recall / cobertura	0,8845 (88,45%)	O modelo identificou cerca de 88% dos e-mails que realmente eram spam.
F1 / F-measure	0,8981 (89,81%)	Resumo do equilíbrio entre precisão e recall.

8. Curva de aprendizagem

Também foi realizado um experimento com proporções de treinamento entre 5% e 95% da base. Nessa análise, foram calculados o F1 no conjunto de treinamento e o F1 no conjunto de teste para cada proporção. O objetivo é observar como a quantidade de exemplos usados no treinamento afeta o desempenho.

No resumo registrado, o F1 de treinamento permaneceu próximo de 0,99, enquanto o F1 de teste ficou aproximadamente entre 0,82 e 0,87. Para a última proporção descrita nesse resumo, foram informados 3.496 exemplos de treinamento, h = 0,5, F1 de treinamento de 0,9920 e F1 de teste de 0,8643. A diferença entre F1 de treino e teste sugere possível sobreajuste: o modelo se ajusta muito bem aos dados usados para aprender, mas tem desempenho inferior em dados separados.

A curva de aprendizagem é um experimento separado e seus valores não devem ser confundidos com as médias da validação cruzada aninhada apresentadas na seção de resultados.

9. Arquivos produzidos

Os resultados foram organizados em arquivos CSV no diretório de saída do projeto. Um arquivo resume as métricas do classificador Parzen e outro registra os valores usados na curva de aprendizagem. Esses arquivos permitem reconstruir tabelas e gráficos e devem ser mantidos junto aos demais resultados do projeto.

10. Conclusão parcial

O classificador Bayesiano por janela de Parzen foi implementado e avaliado na versão original da base Spambase. Nas 300 avaliações externas, apresentou taxa de erro média de 7,90%, precisão de 91,26%, recall de 88,45% e F1 de 89,81%. A validação cruzada interna selecionou h = 0,5 em todas as divisões externas. A curva de aprendizagem apresentou F1 de treino próximo de 0,99 e F1 de teste inferior, sugerindo possível sobreajuste.

Esta etapa atende à parte da Questão 2 referente ao classificador Parzen com os rótulos originais. Ainda é necessário integrar os resultados dos demais classificadores, realizar as comparações estatísticas solicitadas e avaliar os modelos com a variável resposta baseada nos clusters de objetos da Questão 1. Os intervalos de confiança registrados anteriormente devem ser consolidados junto à versão final dos resultados.